4900 · Projeto 2 — Classificador de Documentos e Processos · Guia do Aluno

18/10/2026 · @rodrigo@fortyninehundred.com

Em resumo

Vão construir um motor que lê documentos e lhes atribui três coisas:

- uma **classe de sensibilidade**;
- um **processo de negócio** (RH, Finanças, Jurídico, ...);
- uma **justificação curta**.

O motor corre **100% em local**. Nenhum documento sai do computador.

A mesma coleção pode ser classificada com duas taxonomias, escolhidas pelo administrador:

1. Uma taxonomia empresarial clássica: Público, Uso Interno, Confidencial e Restrito.
2. O modelo de qualificação do Plano Nacional de Nuvem Soberana (RCM n.º 102/2026): níveis 0, 1, 2, 3.a e 3.b, calculados a partir de três dimensões de impacto.

O resultado fica gravado nos metadados do próprio ficheiro (XMP no PDF, propriedades no DOCX). Também sai um inventário em CSV ou JSON.

Na demo final mostram quatro coisas:

- um lote de documentos processado com a rede desligada;
- o mesmo lote classificado com as duas taxonomias;
- os metadados lidos pelo `exiftool`;
- o inventário com a justificação de cada nota.

O problema e porque importa

As organizações guardam milhares de documentos sem saber o que contêm. Um contrato, um processo disciplinar e uma ementa de cantina podem estar na mesma pasta partilhada. Sem saber que documentos são sensíveis, não dá para decidir o que pode ir para a nuvem pública, quem lhes pode aceder ou quanto tempo se guardam.

Classificar à mão não escala. Um motor automático faz uma primeira passagem. Uma pessoa revê depois os casos duvidosos.

O Estado português tornou este problema urgente. A RCM n.º 102/2026 obriga as entidades da Administração Pública a qualificar os seus processos até 30 de junho de 2027. O nível de soberania de cada processo decide onde os dados e os sistemas podem ficar alojados.

Há uma restrição forte: os documentos a classificar são, por definição, potencialmente confidenciais. Enviá-los para uma API externa de IA para os classificar seria a própria fuga que se quer evitar. Por isso, todo o processamento é local.

O referencial da Nuvem Soberana explicado

A RCM n.º 102/2026, de 27 de maio, aprova o Plano Nacional de Nuvem Soberana (PNCS). Leiam o texto completo: tem 7 páginas. Este resumo só cobre o que interessa ao projeto.

1. A RCM qualifica processos, não documentos. O nível aplica-se a um processo de negócio e aos dados e sistemas que o suportam. Um documento herda o nível do processo a que pertence. Por isso o vosso motor faz duas coisas: descobre o processo do documento e atribui-lhe um nível. Este é o ponto conceptual mais importante do projeto.

2. Os quatro níveis de qualificação:

Nível	Nome	O que diz a RCM
0	Neutro	Processos sem requisitos
1	Corrente	Sem requisitos especiais de soberania, mas sujeitos aos requisitos de segurança e soberania da restante legislação
2	Crítico	Requisitos acrescidos de soberania e segurança: soberania de dados e operacional
3.a	Estratégico	Os requisitos mais elevados: soberania de software
3.b	Estratégico	Os requisitos mais elevados: soberania de software de âmbito nacional

3. As três dimensões de impacto. Cada uma é avaliada numa escala de três valores: Sem Impacto, Impacto Moderado ou Impacto Significativo.

- **Pessoas e vida humana:** o comprometimento destes dados pode pôr pessoas em risco?
- **Estabilidade do Estado:** pode afetar o funcionamento do Estado ou da organização?
- **Exposição de dados:** que dano causa a divulgação dos dados?

4. A ponte para os processos é a CLAV. A Plataforma de Classificação e Avaliação da Informação Pública tem o Catálogo de Processos de Negócio da Administração Pública. O CNCS e a ARTE vão publicar uma tabela de pré-qualificação dos processos de 2.º nível desse catálogo.

5. O que a RCM ainda não define. O procedimento de pontuação — como passar das três dimensões para um nível — fica para um referencial técnico do CNCS e da ARTE, publicado em digital.gov.pt. Antes de começarem, verifiquem se já foi publicado.

Se ainda não existir, usem uma regra provisória **vossa**, guardada num ficheiro de configuração. Quando sair o referencial oficial, troca-se a regra sem mudar código. Proposta de partida, que podem rever:

Condição (S = Sem, M = Moderado, G = Significativo)	**Nível**
As três dimensões em S	0 · Neutro
Nenhuma em G e pelo menos uma em M	1 · Corrente
Exatamente uma dimensão em G	2 · Crítico
Duas ou mais dimensões em G	3.a · Estratégico
Nível 3 e o processo está marcado como de controlo nacional (lista configurável)	3.b · Estratégico

Esta tabela é uma hipótese de trabalho e **não é o modelo oficial**. Escrevam isso no relatório e no próprio inventário. O que se avalia é a regra estar documentada, ser configurável e ser aplicada de forma consistente.

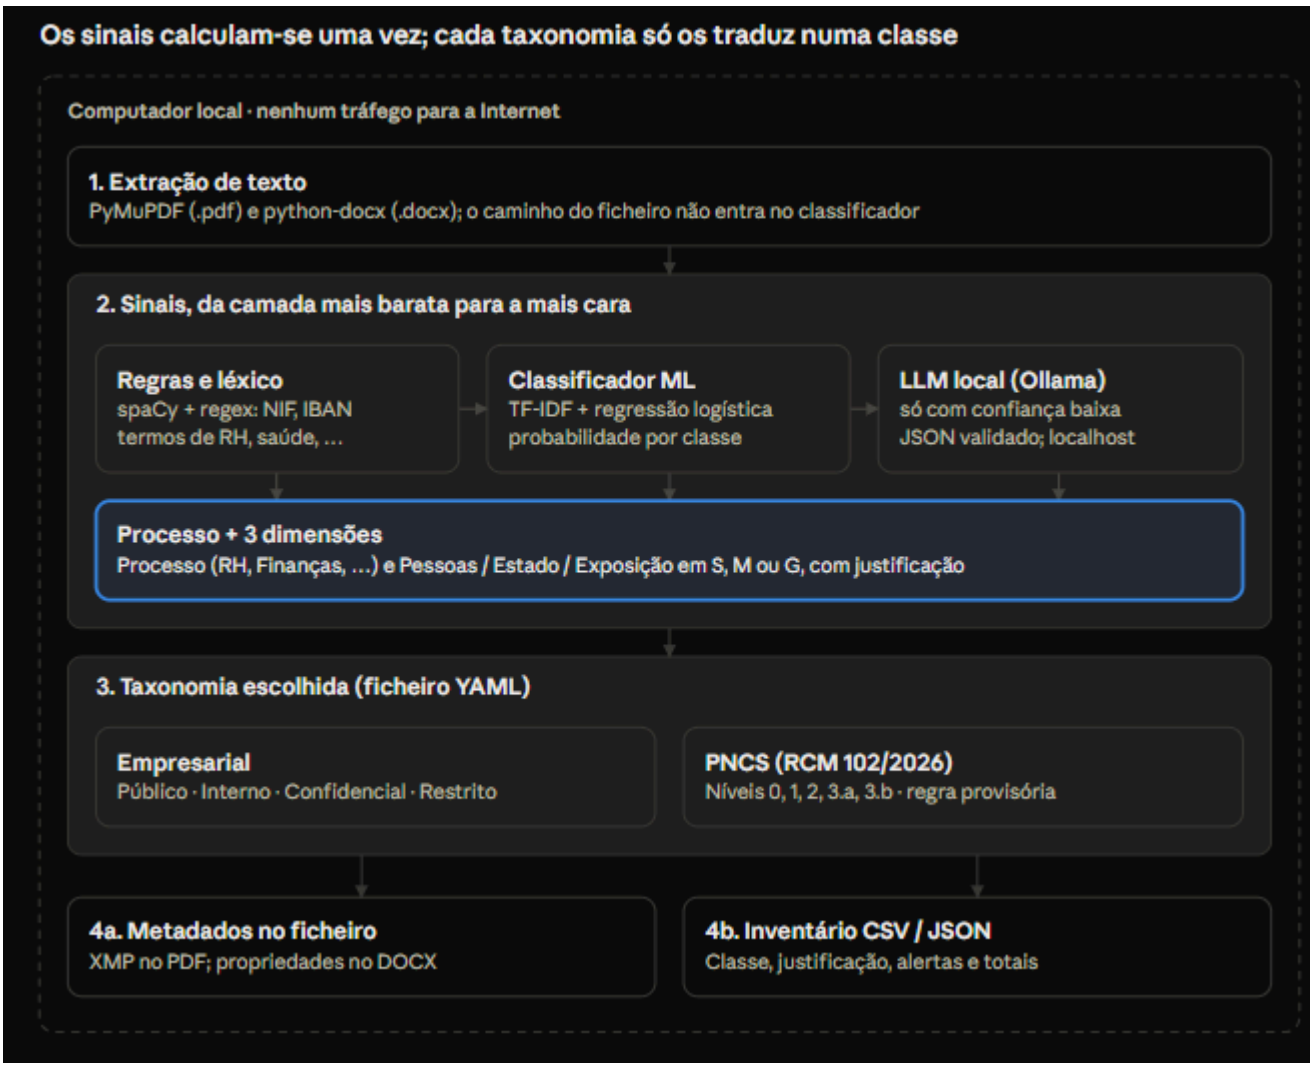
Nota: a RCM reconhece que a maior parte dos dados fica nos níveis mais baixos. Se o vosso motor puser metade dos documentos no nível 3, há algo a rever.

Glossário

Termo	**O que quer dizer**
Taxonomia	Conjunto fechado de classes onde cada documento é colocado, como Público ou Confidencial
Processo de negócio	Conjunto de atividades com um fim, como "recrutamento" ou "pagamento a fornecedores". Os documentos são o rasto desses processos.

CLAV	Plataforma de Classificação e Avaliação da Informação Pública. Tem o catálogo de processos de negócio da Administração Pública, organizado em níveis.
PNCS	Plano Nacional de Nuvem Soberana, aprovado pela RCM n.º 102/2026
Soberania (no PNCS)	Controlo do acesso aos dados e garantia permanente de funcionamento dos sistemas críticos
LLM open-weight	Modelo de linguagem cujos pesos se descarregam e correm localmente, como Llama, Qwen, Gemma ou Mistral
Ollama	Ferramenta que corre LLMs open-weight no computador, com uma API em `localhost`
Zero-shot	Classificar sem exemplos de treino, só com instruções
Few-shot	Classificar com alguns exemplos no próprio pedido
XMP	*Extensible Metadata Platform*. Metadados em XML embebidos no ficheiro. O PDF suporta-o nativamente.
Propriedades DOCX	Metadados do Word: as principais (`core.xml` : título, assunto, palavras-chave, categoria) e as personalizadas (`custom.xml`)
exiftool	Ferramenta de linha de comandos que lê e escreve metadados de quase todos os formatos
Matriz de confusão	Tabela de classes previstas × classes reais. Mostra onde o classificador se engana.

Arquitetura de partida



Os sinais (o processo e as três dimensões) são calculados uma vez por documento. A taxonomia escolhida só os traduz numa classe. Por isso, trocar de taxonomia não obriga a reanalisar o lote. O LLM só entra quando as regras e o ML têm pouca confiança. Esta arquitetura é uma sugestão.

Requisitos explicados

Cada requisito do catálogo vem com três partes: o que significa, como o abordar e como provar que está feito.

R1. Motor de análise e NLP local

O que significa. O texto é extraído e analisado no próprio computador. Nenhum pedido sai para a Internet durante a classificação.

Como abordar. Combinem três camadas, da mais barata para a mais cara:

1. **Regras e léxico.** Palavras e padrões fortes. Exemplos: "recibo de vencimento" aponta para RH, "NIF" e "IBAN" fazem subir a exposição de dados, "diagnóstico" aponta para dados de saúde. São rápidas e fáceis de justificar.
2. **Classificador clássico.** TF-IDF + regressão logística (scikit-learn), treinado no corpus anotado (ver Dados de teste). Dá uma probabilidade por classe.
3. **LLM local via Ollama** (por exemplo, um modelo de 7–8 mil milhões de parâmetros, como Qwen 2.5 ou Llama 3.1). Só é chamado quando as camadas anteriores têm pouca confiança.
   - Peçam a resposta em JSON com esquema fixo: processo, as três dimensões e uma justificação de uma frase.
   - Validem a resposta. Se não for JSON válido, repitam o pedido ou caiam para a camada 2.

Alternativa: um modelo de decisão. Em vez do LLM, ou ao lado dele, pode ser usado um modelo de decisão, como o Laya, o Jev ou outro equivalente.

Estes modelos não geram texto. Recebem o documento e perguntas tipadas e devolvem uma de três coisas:

- uma escolha entre opções;
- uma nota numa escala;
- uma probabilidade, com um valor de confiança.

Encaixam bem neste problema. O processo de negócio é uma escolha. Cada dimensão de impacto é uma nota em S, M ou G. A confiança diz quais documentos vão para revisão humana.

- **Laya:** open-source (Apache 2.0), com uma versão multilíngue. Corre em local, por isso cumpre o requisito R1.
- **Jev** (TypeSafe AI): serviço externo, por API, em acesso antecipado. **Não cumpre o requisito de execução 100% local.** Só pode ser usado como comparação, com documentos sintéticos ou públicos. Nunca entra no lote da demo sem rede, a não ser que exista uma instalação local.

Se escolherem este caminho, comparem o modelo de decisão com o LLM local e com o classificador clássico, nas mesmas métricas e no mesmo conjunto de teste. Justifiquem a escolha no relatório.

Os documentos longos não cabem inteiros no LLM. Usem as primeiras páginas, o título e os excertos onde as regras encontraram sinais.

Como verificar.

- Correr o lote com a rede desligada, ou num contentor com `--network none` e o Ollama no mesmo contentor. Tem de terminar sem erros.
- Correr outra vez com o Wireshark ligado e mostrar que só há tráfego para `127.0.0.1`.

R2. Esquemas de classificação configuráveis

O que significa. O administrador escolhe a taxonomia. Pelo menos duas têm de existir: a empresarial e a do PNCS.

Como abordar.

- Cada taxonomia é um ficheiro YAML com as classes, a descrição de cada uma e a regra de cálculo.
- A taxonomia empresarial pode ser direta: classe = máximo entre a sensibilidade do processo e os sinais do conteúdo. Exemplo: um IBAN obriga a pelo menos Confidencial.
- A do PNCS segue as três dimensões e a tabela de níveis (ver secção anterior).
- O motor produz uma vez os sinais (processo, entidades encontradas, dimensões). Cada taxonomia só os traduz numa classe. Assim, trocar de taxonomia não obriga a reanalisar os documentos.

Como verificar. O mesmo lote corre com `--taxonomy empresa` e com `--taxonomy pncs`. Os dois inventários têm as mesmas linhas e classes diferentes. Acrescentar uma terceira taxonomia só em YAML, sem mudar código, é um bónus.

R3. Mapeamento de processos de negócio

O que significa. Cada documento fica associado a um tipo de processo: Recursos Humanos, Finanças/Faturação, Contratação Pública, Jurídico, I&D ou Outro.

Como abordar.

- Comecem com 6 a 8 processos genéricos.
- Explorem a CLAV e escolham um subconjunto de processos reais da Administração Pública, com o código de cada um.
- Mapeiem os vossos processos genéricos para esses códigos.
- Em cada processo, guardem uma pré-qualificação das três dimensões. O conteúdo concreto do documento só pode fazer **subir** o nível, nunca descer. Exemplo: um documento de Finanças com dados de saúde sobe na dimensão "Pessoas".

Como verificar. Matriz de confusão dos processos no conjunto de teste, com a exatidão e o F1 por processo.

R4. Gravação de metadados persistentes

O que significa. A classe, o processo e a taxonomia usada ficam escritos dentro do ficheiro. Se o ficheiro for copiado para outro sítio, a etiqueta vai com ele.

Como abordar.

- **PDF:** escrevam XMP com um *namespace* vosso, por exemplo `xmlns:cls="https://exemplo.pt/ns/classificacao/1.0/"`, com os campos `cls:Classe`, `cls:Taxonomia`, `cls:Processo` e `cls:Data`.
  - Com o pikepdf: `with pdf.open_metadata() as meta: meta['cls:Classe'] = ...`, depois de registar o namespace.
  - Preencham também `Keywords` no dicionário Info, para os leitores que não leem XMP.
- **DOCX:**
  - Nas propriedades principais, com o python-docx: `core_properties.category` e `core_properties.keywords`.
  - Nas propriedades personalizadas (`docProps/custom.xml`): o python-docx não as suporta diretamente. Editem o XML do pacote ou usem uma biblioteca auxiliar.
- Nunca alterem o conteúdo visível do documento.

Como verificar.

- `exiftool -XMP-cls:all ficheiro.pdf` mostra os campos.
- `exiftool ficheiro.docx` mostra a categoria e as palavras-chave.
- `pdfinfo` mostra as Keywords.
- O ficheiro continua a abrir sem avisos no Acrobat, no Word e no LibreOffice.

R5. Inventário e relatório de auditoria

O que significa. Um resumo do lote: uma linha por ficheiro e totais por classe, com alertas de risco.

Como abordar.

Colunas mínimas do CSV:

- `ficheiro` e `hash_sha256`;
- `taxonomia`, `classe` e `processo`;
- `pessoas`, `estado` e `exposicao` (S, M ou G);
- `confianca`;
- `camada_decisora` (regras, ML ou LLM);
- `justificacao`;
- `alertas`.

Alertas sugeridos:

- documento de nível 2 ou superior numa pasta marcada como "partilhada";
- classe com confiança baixa (para revisão humana);
- dados pessoais em documento classificado como Público.

O JSON leva os mesmos campos e um bloco de totais.

Como verificar. O inventário do lote de demo tem uma linha por ficheiro. Os totais batem certo com a contagem das linhas. Cada justificação refere sinais concretos do documento, como "contém NIF e IBAN; processo Finanças", e não frases genéricas.

Stack sugerida

Peça	Sugestão	Porquê	Alternativa aceite
Linguagem	Python 3.11+	Tem as melhores bibliotecas de PDF, NLP e ML	—
Extração de texto	PyMuPDF (PDF), python-docx (DOCX)	Rápidas e sem dependências externas	Apache Tika em modo local (servidor Java)
Regras e entidades	spaCy `pt_core_news_lg` + regex	NER em português e padrões como NIF e IBAN	—
Classificador clássico	scikit-learn (TF-IDF + regressão logística)	É rápido, explicável e serve de baseline	Sentence-transformers + k-NN
LLM local	Ollama com um modelo de 7–8 mil milhões de parâmetros	Corre em portátil com 16 GB de RAM e tem saída JSON estruturada	`llama.cpp`, HuggingFace Transformers ou um modelo de decisão local (ex.: Laya)
Metadados PDF	pikepdf (XMP)	Escreve XMP sem estragar o ficheiro	PyMuPDF `set_xml_metadata`
Metadados DOCX	python-docx + edição de `custom.xml`	As propriedades principais são nativas; as personalizadas exigem XML	—
Interface	CLI com `typer`	Processamento em lote e fácil de testar	Pequena UI em Streamlit, só local

Prova	`exiftool`, `pdfinfo`, Wireshark	São externas ao projeto	`tcpdump`

Medir a velocidade faz parte do projeto. Um LLM local pode demorar segundos por documento. Registem os documentos por minuto com e sem LLM.

Plano de 14 semanas

[embed: node/1c84da28-00b8]

Cada marco termina com uma reunião de revisão com o orientador. O corpus vem cedo porque tudo depende dele: sem etiquetas de referência não há métricas. O LLM entra depois da baseline para que se possa medir o que ele acrescenta. Se um marco atrasar, cortem primeiro na terceira taxonomia e na UI, não nas provas.

Dados de teste

Usem só documentos públicos ou sintéticos. Nunca usem documentos reais confidenciais, nem os vossos.

Fontes públicas úteis:

- Diário da República: despachos, avisos de concurso, contratos publicados;
- Portal BASE: contratos públicos;
- relatórios e contas de entidades públicas;
- modelos de minutas.

Documentos sintéticos, gerados com templates e Faker `pt_PT`:

- recibos de vencimento;
- processos disciplinares;
- relatórios clínicos;
- propostas de I&D;
- faturas;
- pareceres jurídicos;
- atas.

Objetivo: pelo menos 300 documentos, 30 ou mais por processo, em PDF e DOCX.

Como anotar:

1. Cada documento leva uma etiqueta de referência: processo, as três dimensões (S, M ou G) e a classe empresarial.
2. Dois elementos do grupo anotam uma amostra de 50 documentos de forma independente. Calculem a concordância (kappa de Cohen) antes de anotar o resto.
3. Escrevam um guia de anotação de uma página, com exemplos de cada classe. Sem ele, as etiquetas ficam incoerentes.
4. Separem 20% como conjunto de teste. Não o usem para treinar nem para afinar prompts.

Critérios de conclusão e avaliação

- **Lote sem rede.** Um conjunto diversificado de documentos é processado com a rede desligada. A captura do Wireshark ou das portas abertas mostra zero ligações externas.
- **Duas taxonomias, um lote.** O mesmo conjunto é classificado com a taxonomia empresarial e com o referencial do PNCS. Os dois inventários aparecem lado a lado.
- **Metadados persistentes.** O `exiftool` e o `pdfinfo` leem a classe e o processo nos ficheiros de saída. Os ficheiros abrem sem avisos.
- **Inventário consolidado.** Lista de ficheiros, classes atribuídas e justificação sumária da pontuação, com totais por classe.
- **Métricas.** No conjunto de teste:
  - exatidão e F1 por processo e por classe;
  - matriz de confusão;
  - comparação entre só regras, regras + ML e regras + ML + LLM.

Na classificação de sensibilidade, errar para baixo é pior do que errar para cima. Um documento Restrito marcado como Público é o erro grave. Reportem quantas vezes isso acontece.

Armadilhas comuns

- **Classificar o documento sem pensar no processo.** A RCM qualifica processos. Um documento banal pode pertencer a um processo crítico.
- **Apresentar a regra provisória como se fosse o modelo oficial.** Identifiquem-na sempre como hipótese e verifiquem em digital.gov.pt se o referencial oficial já saiu.
- **Depender só do LLM.** É lento, dá respostas diferentes de uma vez para a outra e é difícil de justificar. Usem-no só nos casos difíceis e fixem `temperature=0`.
- **Confiar que o LLM devolve JSON válido.** Validem a resposta com Pydantic e tenham um plano B.
- **Esquecer que o Ollama também pode ir à rede.** Descarreguem os modelos antes da demo. Durante a prova, o único tráfego permitido é para `localhost`.

- **Partir o ficheiro ao gravar metadados.** Testem cada ficheiro de saída no Acrobat, no Word e no LibreOffice, não só no `exiftool`.
- **Gravar uma versão incremental do PDF com assinatura digital.** A assinatura deixa de ser válida. Detetem PDFs assinados e não lhes mexam: registem no inventário.
- **Avaliar no conjunto usado para afinar os prompts.** Dá números falsamente bons.
- **Pastas como pista escondida.** Se os documentos de treino estiverem em pastas com o nome do processo, o modelo pode aprender o nome da pasta. Não passem o caminho do ficheiro ao classificador.

Ética e segurança do projeto

- Só documentos públicos ou sintéticos (ver Dados de teste).
- O motor recomenda uma classe. Num uso real, a decisão final é de uma pessoa. O inventário deve facilitar essa revisão: confiança, justificação e alertas.
- O inventário também é sensível: diz onde estão os documentos mais críticos. Tratem-no como Confidencial e não o ponham no repositório com dados reais.
- O relatório deve dizer claramente que a regra de níveis usada é provisória e não é o referencial oficial do CNCS e da ARTE.

Entregáveis finais

Entregável	O que inclui
Repositório Git	Motor, taxonomias em YAML, testes, scripts de geração do corpus e histórico de commits ao longo do semestre
README	Instalação (incluindo o download do modelo Ollama), uso da CLI com as duas taxonomias e como reproduzir a prova sem rede
Relatório técnico (15–25 páginas)	Enquadramento do PNCS, regra provisória e justificação, arquitetura, métricas por camada, provas de metadados e de isolamento, limitações
Demo (ao vivo ou vídeo de 5–10 min)	Lote sem rede, duas taxonomias, `exiftool` e inventário
Corpus e guia de anotação	Os documentos (ou o script que os gera), as etiquetas e o kappa da amostra dupla

Leituras e recursos

- Resolução do Conselho de Ministros n.º 102/2026, de 27 de maio: Plano Nacional de Nuvem Soberana. Leitura obrigatória, em especial a secção 3 do anexo.
- digital.gov.pt: onde serão publicados o referencial técnico, a metodologia de qualificação e a tabela de pré-qualificação.
- Plataforma CLAV: Catálogo de Processos de Negócio da Administração Pública.
- Comissão Europeia, *Cloud Sovereignty Framework*.
- Decreto-Lei n.º 125/2025, que transpõe a Diretiva NIS 2, como contexto de cibersegurança.
- Documentação do Ollama: API local e saídas estruturadas (*structured outputs*).
- Documentação do pikepdf: *Metadata* (XMP).
- Adobe, especificação XMP, parte 1.
- scikit-learn: *Working with text data*.